

DISCIPLINA: RACIOCÍNIO MATEMÁTICO PARA COMPUTAÇÃO
RELATÓRIO TÉCNICO: APRENDIZADO DE MÁQUINA SUPERVISIONADO

ALUNOS : Giovanni Martins Villar Torino ,Emerson Cavalheiro Bode, Matheus Oliveira da Silva

CINE ESCOLHA

Análise e Implementação de um Sistema de Recomendação Automatizado via Árvores de Decisão

1. Contextualização do Problema

Com o avanço das plataformas de streaming e a massiva digitalização do acervo cinematográfico mundial, os usuários de sistemas computacionais de entretenimento veem-se frequentemente diante do fenômeno psicológico e operacional conhecido como "paralisia de escolha". A abundância de opções disponíveis resulta em um aumento ineficiente do tempo gasto na navegação e seleção de títulos, degradando a experiência do consumidor final.

O presente trabalho aborda esse problema por meio do desenvolvimento da plataforma Cine Escolha. Trata-se de uma aplicação que une uma infraestrutura de backend em Python (Flask) a um modelo de Aprendizado de Máquina Supervisionado. O objetivo prático é prever de forma automatizada se um determinado filme atende aos critérios qualitativos mínimos para ser classificado como Recomendado (1) ou Não Recomendado (0), permitindo que o usuário receba uma ordenação personalizada de títulos com base em preferências de gênero, duração ou avaliação.

2. Dados Utilizados

A base de dados empregada no desenvolvimento do modelo consiste em uma amostragem estruturada contendo registros históricos de produções cinematográficas pertencentes a seis categorias distintas (Ação, Comédia, Drama, Terror, Romance e Animação). Para cada obra, foram coletadas e tratadas características quantitativas e categóricas.

Características (Features) Utilizadas:

- **genero_cod:** Variável discreta numérica que mapeia o gênero da produção (valores inteiros de 0 a 5).
- **duracao_min:** Variável contínua referente ao tempo de execução do filme expresso em minutos.
- **avaliacao:** Métrica contínua decimal refletindo a nota atribuída pela crítica especializada e público (escala de 0.0 a 10.0).
- **ano:** Variável discreta que indica o ano de lançamento cronológico da obra.
- **popularidade:** Índice numérico de engajamento e procura do filme junto ao ecossistema digital (escala de 0 a 100).

Saída Esperada (Target Label):

A variável dependente (alvo) é denominada recomendado. Trata-se de uma flag binária calculada de forma determinística na base de treino para fins pedagógicos, onde $y = 1$ se avaliacao ≥ 7.5 , e $y = 0$ caso contrário.

Tabela 1: Tabela 1: Amostragem Parcial da Base de Dados (Matriz Histórica de Filmes)

Título do Filme	Gênero (Cod)	Duração (min)	Avaliação	Ano	Popularidade	Recomendado (y)
Velocidade Máxima	0 (Ação)	120	7.8	2019	85	1
Guerra Total	0 (Ação)	150	6.5	2021	60	0
Missão Impossível X	0 (Ação)	130	8.2	2023	95	1
Risadas Garantidas	1 (Comédia)	95	7.0	2020	70	0
Tá Todo Mundo Louco	1 (Comédia)	90	8.0	2022	88	1
Lágrimas do Passado	2 (Drama)	140	8.5	2021	75	1
O Último Adeus	2 (Drama)	135	9.0	2023	90	1
Sombras na Noite	3 (Terror)	90	6.8	2020	65	0
A Casa Amaldiçoada	3 (Terror)	100	7.5	2022	80	1
Amor à Primeira Vista	4 (Romance)	105	7.6	2021	78	1
Aventura Mágica	5 (Animação)	90	8.7	2023	96	1
Mundo dos Sonhos	5 (Animação)	92	9.2	2023	98	1

3. Representação Matemática

Em conformidade com os conceitos fundamentais de Álgebra Linear e Raciocínio Matemático, a estrutura de dados de entrada do modelo supervisionado é formalizada por meio de uma matriz de características X e um vetor coluna de saídas obtidas y .

Considerando um espaço multidimensional onde cada filme representa uma instância m e cada atributo representa uma dimensão n , definimos a matriz de entrada $X \in \mathbb{R}^{24 \times 5}$ e o vetor de saída $y \in \mathbb{R}^{24}$ estruturados com o formato clássico de tensores retangulares bidimensionais:

$$X = \begin{bmatrix} 0, & 120, & 7.8, & 2019, & 85 \\ 0, & 150, & 6.5, & 2021, & 60 \\ 0, & 130, & 8.2, & 2023, & 95 \\ 1, & 95, & 7.0, & 2020, & 70 \\ \vdots & & & & \\ 5, & 92, & 9.2, & 2023, & 98 \end{bmatrix}, \quad y = [1, 0, 1, 0, \dots, 1]^T$$

Cada linha x_i da matriz X mapeia um vetor linha no espaço linear de características de dimensão 5 ($\mathbb{R}^5$). O objetivo intrínseco do modelo de aprendizado supervisionado consiste em inferir uma função preditiva aproximada $f: \mathbb{R}^5 \rightarrow \{0, 1\}$, minimizando o erro de predição em relação aos rótulos reais observados no vetor y .

4. Modelo Supervisionado

O problema proposto enquadra-se estritamente na categoria de Classificação Binária. A escolha justifica-se pelo fato de o vetor target y mapear classes discretas, qualitativas e mutuamente exclusivas (o filme pertence ao grupo recomendado ou não pertence), diferindo de problemas de regressão onde o objetivo é estimar valores contínuos e infinitos.

O algoritmo adotado para solucionar a tarefa tarefa preditiva foi a Árvore de Decisão (DecisionTreeClassifier), configurada com profundidade máxima restrita a 4 (`max_depth=4`) com o intuito de mitigar cenários de sobreajuste (overfitting) e manter a interpretabilidade das regras geométricas geradas.

O processo de treinamento dá-se seguindo a metodologia clássica de divisão holdout. Utilizando a biblioteca scikit-learn, a matriz X e o vetor y são particionados na proporção de 75% para o conjunto de treinamento e 25% para validação via testes. Adicionalmente, empregou-se a amostragem estratificada (`stratify=y`), garantindo que as proporções de classes recomendadas e não recomendadas mantenham-se equilibradas e idênticas em ambas as partições amostrais.

5. Explicação Teórica do Modelo

Uma Árvore de Decisão baseia-se em um modelo estatístico não-paramétrico que particiona o espaço de características em hiperretângulos ortogonais aos eixos através de cortes sucessivos. O objetivo primordial é dividir progressivamente os dados originais em subconjuntos cada vez mais puros com base em critérios de homogeneidade.

A escolha de cada ponto de divisão (nó) é determinada pela minimização de métricas de impureza, como o Índice Gini ou a Entropia. O algoritmo avalia todas as features e pontos de corte possíveis, escolhendo aquele que maximiza o ganho de informação (redução da impureza). Quando um

vetor de entrada desconhecido é submetido ao modelo, ele percorre o fluxo condicional desde o nó raiz, passando pelos nós intermediários baseados em inequações lógicas até atingir uma folha terminal, onde extrai-se a predição da classe prevalecente ou a probabilidade contínua associada à sua distribuição de frequência interna (predict_proba).

6. Implementação em Python

Abaixo detalha-se a arquitetura de engenharia de dados e treinamento contida no arquivo api.py:

```
# 1. Carga Estruturada dos Dados (Matrizes de Features)
df = pd.DataFrame(FILMES_RAW, columns=["titulo", "genero_cod", "duracao_min",
"avaliacao", "ano", "popularidade"])
df["genero"] = df["genero_cod"].map(GENEROS)

# Construção Matemática da Variável Alvo (Label)
df["recomendado"] = (df["avaliacao"] >= 7.5).astype(int)

FEATURE_COLS = ["genero_cod", "duracao_min", "avaliacao", "ano", "popularidade"]
X = df[FEATURE_COLS].values
y = df["recomendado"].values

# 2. Divisão Amostral Estratificada e Treinamento
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.25, random_state=42, stratify=y
)

modelo = DecisionTreeClassifier(max_depth=4, random_state=42)
modelo.fit(X_train, y_train)

# 3. Computação Estatística da Probabilidade (Score)
def calcular_score(linha):
    features = np.array([
        linha["genero_cod"], linha["duracao_min"],
        linha["avaliacao"], linha["ano"], linha["popularidade"],
    ])
    proba = modelo.predict_proba(features)[0]
    return round(float(proba[1]), 3)
```

7. Resultados e Discussão

Após a compilação do fluxo de execução do script de aprendizado de máquina, o modelo computou a acurácia no conjunto invisível de testes utilizando a função `accuracy_score`. Essa métrica expressa a fração de predições corretas geradas sobre a partição holdout.

O ecossistema interage diretamente com o frontend web contido no arquivo `index.html`. Quando o usuário requisita uma recomendação, a API Flask filtra os candidatos elegíveis e invoca a função `calcular_score`, retornando a probabilidade precisa calculada pela árvore de decisão para a classe 1 (Recomendado). A interface renderiza o resultado sob a ótica de 'Compatibilidade Prevista' (ex: probabilidade de 0.950 mapeia para 95% de compatibilidade), entregando os três títulos mais adequados ordenados de forma decrescente pelo score.

Limitações Técnicas do Modelo:

- **Vazamento de Dados (Data Leakage):** Devido à natureza simplificada da modelagem escolar, a variável target y foi sintetizada usando diretamente uma inequação sobre a coluna avaliacao. Isso faz com que a Árvore de Decisão isole de forma quase absoluta o atributo avaliativo nas tomadas de decisão, mascarando o real peso preditivo das demais características.
- **Volumetria do Dataset:** A matriz amostral restringe-se a 24 registros, o que caracteriza um volume estatístico muito baixo para generalização estável em cenários reais de produção.